

1ST WORKSHOP — DATA ENGINEERING

Amazon Redshift

Un data warehouse cloud pour notre PME ?
Analyse critique, coûts réels et démonstration

Victor Giordani · Membre 2 · Membre 3 · Membre 4

Vendredi 12 juin 2026 — 12 minutes + questions

Point de départ : la prod qui souffre

Scénario : HelvetiCart, e-commerce suisse de 80 personnes. Tout vit dans le PostgreSQL de production.

Dashboards lents

Les agrégations BI sur 45 M de commandes prennent plusieurs minutes.

Prod menacée

Chaque analyse ad-hoc des data analysts ralentit le site marchand.


Données éclatées

Commandes, clickstream (200 M d'événements), exports marketing : ~600 GB non centralisés.

Question à trancher : faut-il décharger l'analytique vers un data warehouse dédié — et Redshift est-il le bon choix ?

Deux idées : colonnaire + parallèle

ARCHITECTURE MPP



Compute et stockage découplés : on les paie — et on les dimensionne — séparément.

- Stockage colonnaire : on ne lit que les colonnes utiles → scans 10-100× plus rapides qu'un row-store pour l'analytique.
- MPP : la requête est découpée et exécutée en parallèle sur plusieurs nœuds.
- SQL compatible PostgreSQL : les analysts gardent leurs outils (psql, BI, drivers JDBC).
- Deux modes : cluster provisionné (RA3) ou Serverless, facturé à la seconde d'activité.

Le vrai... et le marketing

Tient ses promesses

- Excellent sur les agrégations massives (validé par le paper SIGMOD'22)
- Intégration AWS native : S3, IAM, Glue, QuickSight, zero-ETL Aurora
- Serverless : vraiment zéro administration de cluster

À relativiser

- « Jusqu'à 5× moins cher » : vrai seulement sur des benchmarks choisis
- « Sans tuning » : DISTKEY / SORTKEY / VACUUM comptent encore en provisionné
- Latence plancher ~100 ms même sur SELECT 1 — inadapté au temps réel applicatif
- Concurrency limitée sans concurrency scaling (payant)

Combien ça coûterait ?

Hypothèses : Redshift Serverless à Frankfurt, base 8 RPU, ~3 h de compute facturé par jour ouvré, 600 GB.

Poste	Calcul	\$ / mois
Compute Serverless	$8 \text{ RPU} \times 3 \text{ h} \times 22 \text{ j} \times \$0.39/\text{RPU-h}$	≈ 206
Stockage géré	$600 \text{ GB} \times \$0.024/\text{GB-mois}$	≈ 14
S3 staging + divers	forfait	≈ 10
Total		≈ 230 \$ (~185 CHF)

≈ 230 \$

par mois — moins qu'un jour-
homme d'ingénieur

- Minimum 60 s facturées à chaque réveil : les petites requêtes éparses coûtent proportionnellement cher.
- Pas de plafond par défaut → configurer des usage limits dès le jour 1, sinon la facture est imprévisible.

Lock-in : où est-on réellement captif ?

Les données

FAIBLE

UNLOAD exporte tout en Parquet ouvert vers S3. La donnée sort facilement (hors frais egress AWS).

Le SQL

MOYEN

Dialecte ~PostgreSQL, mais COPY, DISTKEY/SORTKEY, tables système et Spectrum sont propriétaires.

Les pipelines & l'IAM

FORT

Ingestion, rôles, monitoring, BI : tout est tissé dans AWS. C'est ça, le vrai coût de sortie.

Mitigation : garder les données brutes en Parquet sur S3 (pattern lakehouse) — Redshift devient un moteur remplaçable, pas un coffre-fort.

Démo : HelvetiCart sur Redshift Serverless

1

Générer

5 M de commandes
synthétiques (CSV gzip, ~150
MB) uploadées sur S3

2

Charger

COPY depuis S3 : chargement
massif parallèle en < 30
secondes

3

Analyser

Requêtes BI réelles : CA
mensuel, top catégories par
canton, clients fidèles

4

Casser

Et la contre-épreuve : ce que
Redshift fait mal, en direct

Budget démo : 0 CHF — crédits d'essai de \$300 / 90 jours offerts sur Redshift Serverless.

(captures d'écran de secours prévues si la démo live tousse)

Ce que la démo montre

Force : l'analytique massive

~1-2 s

pour agréger le CA mensuel sur 5 M de lignes — la même requête prend plusieurs minutes sur le Postgres de prod chargé.

Bonus : result cache → re-run instantané pour les dashboards.

Faiblesse : le transactionnel

~minutes

pour 1 000 INSERTs ligne à ligne (< 1 s sur Postgres). Et même SELECT 1 met ~100 ms.

Redshift ne remplace pas la base de prod — il la complète.

Nos recommandations

UTILISEZ REDSHIFT SI...

- Analytique sur > 100 GB et requêtes d'agrégation lourdes
- Charge BI / batch intermittente → Serverless facture à l'usage
- Vous êtes déjà sur AWS (S3, IAM, Aurora)
- Équipe à l'aise en SQL, pas envie d'administrer un cluster

ÉVITEZ-LE SI...

- < quelques dizaines de GB : votre PostgreSQL suffit largement
- Besoin OLTP ou latence < 100 ms côté application
- Stratégie multi-cloud ou aversion forte au lock-in AWS
- Personne pour surveiller les coûts → préférer un forfait prévisible

NOTRE VERDICT POUR HELVETICART

Oui à Redshift Serverless — avec trois garde-fous

~230 \$/mois

pour décharger la prod et accélérer la BI : le ROI est immédiat.

Usage limits

configurées dès le premier jour pour rendre la facture prévisible.

Parquet sur S3

comme source de vérité : le moteur reste remplaçable demain.

Questions ?

Pour aller plus loin

- Documentation & pricing officiels — aws.amazon.com/redshift (pricing, FAQ, free trial)
- Armenatzoglou et al., « Amazon Redshift Re-invented », SIGMOD'22 — l'architecture en détail
- Billing Serverless — docs.aws.amazon.com/redshift/latest/mgmt/serverless-billing.html
- Comparatifs critiques : CloudZero « Redshift Pricing Guide » ; Striim « Cloud DW Comparison » ; Definite « Snowflake alternatives for startups »
- Notre démo : scripts SQL + générateur de données fournis avec la cheat sheet

Cheat sheet ingénieur (2 pages) distribuée en complément : démarrage, commandes clés, pièges.